

# $M$ -оценки и ОМП

422 группа

Tue 28 Feb 2017

## Содержание

<b>1</b>	<b><math>M</math>- и <math>Z</math>-оценки</b>	<b>1</b>
<b>2</b>	<b>Состоятельность</b>	<b>2</b>
2.1	Сходимость к чему-нибудь . . . . .	2
2.2	Равенство $\theta^* = \theta_0$ . . . . .	3
<b>3</b>	<b>Скорость сходимости</b>	<b>3</b>
<b>4</b>	<b>Доверительные границы</b>	<b>4</b>
4.1	Аппроксимация Вальда . . . . .	4
4.2	Метод профилей правдоподобия . . . . .	4

## 1 $M$ - и $Z$ -оценки

По выборке  $\mathbf{x} = (x_1, \dots, x_n)$ , оценим параметр  $\theta \in \Theta$ . Введем функцию-критерий

$$m_\theta : \mathcal{X} \rightarrow \bar{\mathbb{R}},$$

показывающую насколько наблюдения соответствуют параметру и отображение

$$\theta \mapsto M_n(\theta) = \frac{1}{n} \sum_{i=1}^n m_\theta(x_i),$$

сопоставляющее каждому параметру его «подходящесть».

**Определение** ( $M$ -оценка<sup>1</sup>). По принципу «наилучшей хорошесть», оценка есть

$$\hat{\theta}_n = \operatorname{argmax}_{\theta} M_n(\theta).$$

*Замечание.* Чтобы  $\hat{\theta}_n$  было случайной величиной, требуем, чтобы  $\hat{\theta}_n$  было измеримым, а для этого, чтобы  $\Theta$  — польским (полным, измеримым, метрическим).

*Замечание.* Если взять  $m = \log p_\theta$ , то  $M$ -оценка есть ОМП.

**Определение** ( $Z$ -оценка<sup>2</sup>). Рассмотрим другие критерии  $\psi_\theta(x)$  и отображение

$$\theta \mapsto \Psi_n(\theta) = \frac{1}{n} \sum_{i=1}^n \psi_\theta(x_i).$$

В качестве оценки найдем

$$\hat{\theta}_n = \operatorname{root}_{\theta} \Psi_n(\theta).$$

---

<sup>1</sup> «Maximum»

<sup>2</sup> «Zero»

*Замечание.*  $M$ -оценка может быть сведена к этой оценке  $\psi_\theta = \partial m_\theta / \partial \theta$ .

*Замечание.*  $\psi_\theta$  должна быть, конечно, дифференцируема.

**Пример.** Пусть  $x_1, \dots, x_n$  i.i.d. на  $U[0, \theta)$ , то  $p_\theta = \theta^{-1} \mathbf{1}_{[0, \theta)}$  и

$$\theta \mapsto \sum_{i=1}^n (\log \mathbf{1}_{[0, \theta)}(x_i) - \log(\theta)).$$

Максимум  $z$ -оценки достигается на

$$\hat{\theta}_n = \max x_i.$$

ОМП оценку не найти, потому что не продифференцировать индикатор.

## 2 Состоятельность

Пусть есть

$$M_n(\theta) = \frac{1}{n} \sum_{i=1}^n m_\theta(x_i) \xrightarrow[n \rightarrow \infty]{P} \mathbb{E} m_\theta = M(\theta) = \int m_\theta d\mathcal{P}_x.$$

Навесим  $\operatorname{argmax}$  на обе стороны:

$$M_n(\theta) \rightsquigarrow \hat{\theta}_n = \operatorname{argmax}_\theta M_n(\theta).$$

Если бы  $\operatorname{argmax}$  было непрерывным, то  $\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{P} \theta^* = \operatorname{argmax} M(\theta)$ . Нужно проверить следующие вещи:

1. Сходится ли  $\hat{\theta}_n$  хоть к чему-нибудь.
2. Правда ли, что  $\theta^* = \theta_0$ .

$\operatorname{argmax}$  в принципе не является непрерывным. До тех пор, пока находимся в области притяжения параметра, всё хорошо, но как только из нее выходим, можем резко перескочить на другой экстремум.

### 2.1 Сходимость к чему-нибудь

**Теорема (Вальд).** Рассматриваем  $M$ -оценку. Пусть

1.  $m_\theta$  полунепрерывна сверху по  $\theta$  для почти всех  $x$ :

$$\lim_{\theta \rightarrow \theta_0} \sup \leq m_{\theta_0}, \quad \text{для почти всех } x.$$

(если экстремум в  $\theta_0$ , то он хорошо выражен).

2.  $\operatorname{argmax}$  должно быть случайной величиной. Для этого отображение

$$\forall B_\delta \subset \Theta \quad x \mapsto \sup_{\theta \in B_\delta} m_\theta(x)$$

должно быть

- a) измеримо
- b) ограничено:

$$\int \sup_{B_\delta} m_\theta(x) d\mathcal{P} < \infty.$$

*Замечание.* Пусть  $\Theta^* = \{\theta^* \in \Theta : M(\theta^*) = \sup_{\theta} M(\theta)\}$ . Еще ослабим условие: максимум будет достигаться асимптотически. Пусть интересуется

$$\hat{\theta}_n = \operatorname{argmax}(M_n(\theta) - o(1))$$

(не доходим до максимума — с точки зрения приложений ок, потому что ищем оценки численно). Т.е. интересуемся

$$M_n(\hat{\theta}_n) \geq c \sup_{\theta} M_n(\theta), \quad c \xrightarrow{n \rightarrow \infty} 1, \quad 0 \leq c < 1.$$

Тогда для любой такой последовательности оценок,  $\forall \epsilon > 0 \forall K \subset \Theta$  ( $K$  — компакт), верно, что

$$\mathbb{P} \left( \operatorname{dist}(\hat{\theta}_n, \theta^*) \geq \epsilon, \hat{\theta}_n \in K \right) \xrightarrow{n \rightarrow \infty} 0.$$

Иными словами, это условие на то, как оценка не сходится — либо последовательность сходится, либо выходит за компакт.

**Следствие.** Поэтому для  $\mathbb{R}^n$  всё либо сходится по вероятности, либо уходит на бесконечности — не может колебаться на манер  $(-1)^n$ . Это очень здорово.

## 2.2 Равенство $\theta^* = \theta_0$

Говорили, что ОМП получают, когда

$$M_n(\theta) = \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(x_i).$$

Совершим трюк: добавим константу, так что

$$M_n(\theta) = \frac{1}{n} \sum_{i=1}^n \log \frac{p_{\theta}(x_i)}{p_{\theta_0}(x_i)}.$$

На максимум не влияет, конечно. Тогда

$$\frac{1}{n} \sum_{i=1}^n \log \frac{p_{\theta}}{p_{\theta_0}}(x_i) \xrightarrow{\mathbb{P}} \int_{\mathbb{R}} \log \left( \frac{p_{\theta}(x)}{p_{\theta_0}(x)} \right) p_{\theta_0}(x) dx = \mathbb{E} \log \frac{p_{\theta}}{p_{\theta_0}} \leq \ln \mathbb{E} \frac{p_{\theta}}{p_{\theta_0}} = \ln \int_{\mathbb{R}} \frac{p_{\theta}}{p_{\theta_0}}(x) p_{\theta_0}(x) dx = \ln 1 = 0$$

так что

$$M(\theta) \leq 0.$$

Интересуемся  $\theta : M(\theta) = 0$ . Это так, когда  $p_{\theta} = p_{\theta_0}$  для почти всех  $x$ . В предположении свойства *идентифицируемости* задачи ( $\theta_1 \neq \theta_2 \implies \mathcal{P}_{\theta_1} \neq \mathcal{P}_{\theta_2}$ ), получаем  $\theta = \theta_0$ .

Таким образом, нужно иметь адекватную модель (выполнялось бы условие идентифицируемости). Для выполнимости теоремы Вальда достаточно компактности и  $\sqrt{\log p} \dots$  Компактность на практике выполняется — можно взять достаточно большой отрезок всегда.

Так что состоятельность выполняется.

## 3 Скорость сходимости

При выполнении некоторых условий регулярности (простые почти никогда не выполняются, сложные сложно проверить) ОМП асимптотически нормальны, т.е.

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, I^{-1}(\theta_0)).$$

Если условия регулярности не выполняются, может быть все что угодно. Обычно, если  $\Theta = \mathbb{R}^n$ , то оценки сходятся оч быстро. Иначе медленно.

## 4 Доверительные границы

### 4.1 Аппроксимация Вальда

Исходя из нормальной аппроксимации, доверительные границы можно

$$\left(\hat{\theta}_n - \theta_0\right)^T \Sigma^{-1} \left(\hat{\theta}_n - \theta\right) \xrightarrow{d} \chi_d^2.$$

Проблемы:

- Границы лишь асимптотические.
- Нужно знать  $\Sigma$ , зависящую от оцениваемого параметра. Поэтому нужно еще и оценивать  $\Sigma^{-1}$ .

Так можно делать в низких размерностях и при больших выборках.

### 4.2 Метод профилей правдоподобия

Пусть есть  $\theta$ ,  $\dim \theta = k$ . НУО, выделим  $\theta = (\theta_1, \theta_2)$ ,  $\dim \theta_1 = k_1$ . Рассмотрим логарифм функции правдоподобия как функцию двух аргументов

$$\ell(\theta) = \ell(\theta_1, \theta_2).$$

Построим *профиль*

$$r(\theta_2) = \ell(\hat{\theta}_1(\theta_2), \theta_2),$$

где  $\hat{\theta}_1(\theta_2)$  — MLE оценка  $\theta_1$  с данным  $\theta_2$ :  $\hat{\theta}_1(\theta_2) = \operatorname{argmax}_{\theta_1} \ell(\theta_1, \theta_2)$ .

*Замечание.* Если  $\theta_2 = (\hat{\theta}_2)_{\text{MLE}}$ , то  $\hat{\theta}_1(\hat{\theta}_2)_{\text{MLE}} = (\hat{\theta}_1)_{\text{MLE}}$ .

*Утверждение.* Пусть истинный параметр  $\theta_0 = (\theta_{10}, \theta_{20})$ . Тогда

$$z^2 := -2 \left( r(\theta_{10}) - \ell(\hat{\theta}_n) \right) \xrightarrow{d} \chi^2(k_1).$$

*Идея доказательства.* Знаем, что  $\hat{\theta}_n$  имеет нормальное распределение,  $\ell(\hat{\theta}_n) \sim \chi^2$ . Тогда в пределе  $\ell$  должна выглядеть как сумма квадратов — можно разложить по Тейлору, будет что-то вроде

$$\dots + \frac{1}{2} \left( \theta_0 - \hat{\theta}_n \right)^2 + \dots$$

Условия регулярности нужны чтобы убить все члены старше второго.  $\square$

Нужно уметь обращаться  $r$ , чтобы

$$\theta_{10} : \operatorname{qnt}_{\chi^2}(\gamma_1) \leq -2(\dots) \leq \operatorname{qnt}_{\chi^2}(\gamma_2).$$

Так что заменили задачу оценивания  $\Sigma^{-1}$  на задачу обращения детерминированной функции  $r$ . В качестве бонуса — профиль должен быть похож на квадратичную функцию, тогда доверительный интервал по квантилям будет правильно выбран (частный случай «локальной асимптотической нормальности»).

На глаз можно посмотреть график  $|z|$ . Когда всё хорошо, он будет выглядеть как модуль.

**Пример.** Пусть  $\xi \sim N(\mu_0, \sigma_0^2)$ ,  $\theta = (\mu, \sigma^2)$ . Пусть  $\mu_0$  известна; оценим по выборке  $\sigma^2$ . Т.к.  $\chi^2(1) = (N(0, 1))^2$ , то

$$z^2 = -2 \left( \underbrace{r(\mu_0)}_{\max_{\sigma^2} \ell(\mu_0, \sigma^2)} - \ell(\mu_0, \hat{\sigma}^2) \right) \xrightarrow{d} (N(0, 1))^2.$$

Значит  $z \xrightarrow{d} N(0, 1)$ . Ясно, что в  $\hat{\sigma}^2 = \hat{\sigma}_{\text{MLE}}^2$ ,  $|z| = 0$ . На остальных значениях это модуль-галочка, причем по значениям  $|z|$  — квантилям  $N(0, 1)$  — можно построить доверительный интервал для  $\hat{\sigma}^2$ .

*Замечание.* В R — пакет `bbmle`, функция `mle2`. На выходе — объект типа `mle`. Это оценки +  
.... `summary(mle)`. Построить профиль можно при помощи функции `p <- profile(m)`. Вызывает  
`optim` и т.п. Профили можно рисовать: `plot(p)`. Подсчет доверительных интервалов: `confint(p)`.