

Моделирование методом отбора (Rejection Sampling)

422 группа

Tue 07 Mar 2017

Содержание

| | | |
|----------|--------------------------------------------------|----------|
| 1 | Схема метода | 1 |
| 1.1 | Мотивация | 1 |
| 1.2 | Формальный алгоритм | 2 |
| 1.3 | Трюки | 2 |
| 2 | Адаптивный метод отбора | 3 |
| 2.1 | Мажоранта | 3 |
| 2.1.1 | Моделирование кусочно-экспоненциальной плотности | 3 |
| 2.2 | Миноранта | 4 |
| 2.3 | Алгоритм | 4 |
| 2.4 | ARS с ушами | 5 |

1 Схема метода

1.1 Мотивация

Пусть $p(x) = \text{pdf}_{\mathcal{P}}(x)$, H — подграфик.

Предложение. Если $(\xi_1, \xi_2) \sim U(H)$, то $\xi_1 \sim \mathcal{P}$.

Доказательство. Действительно,

$$P(\xi_1 < z) = \int_{-\infty}^z dx \int_0^{p(x)} dy = \int_{-\infty}^z p(x) dx.$$

□

Алгоритм. Пусть $g(x)$ — мажоранта, $|\text{supp } \mathcal{P}| < \infty$.

1. $x \leftarrow U(\text{supp } \mathcal{P})$, $y \leftarrow U(0, g(x))$
2. Если $y < p(x)$, $\xi \leftarrow x$, конец; иначе 1.

Алгоритм (Частный случай). Пусть $p(x)$ сосредоточена на $[0, 1]$, $g(x) \equiv M$.

1. Для $t \in 1, 2, \dots$

$$\begin{aligned}\alpha_1^{(t)} &\sim U(0, 1) \\ \alpha_2^{(t)} &\sim U(0, 1).\end{aligned}$$

2. Если

$$p(\alpha_1^{(t)}) \geq M\alpha_2^{(t)},$$

$\xi \leftarrow \alpha_1^{(t)}$, конец; иначе 1.

1.2 Формальный алгоритм

Пусть \mathcal{Q} — мажорирующее распределение, т.е. $p(x) \leq Mq(x) = g(x) \forall x$ и существует производная Радона–Никодима $r = d\mathcal{P}/d\mathcal{Q} \leq M$.

Алгоритм (Общий).

1. Для $t \in 1, 2, \dots$

$$\begin{aligned}\eta^{(t)} &\sim \mathcal{Q} \\ \alpha^{(t)} &\sim U(0, 1).\end{aligned}$$

2. Если

$$r(\eta^{(t)}) \geq M\alpha^{(t)},$$

или (поскольку $r = p/q$) что то же самое,

$$\frac{p(\eta^{(t)})}{g(\eta^{(t)})} \geq \alpha^{(t)},$$

то $\tau = t$; $\xi \leftarrow \eta^{(\tau)}$; конец; иначе 1.

Утверждение. Справедливо:

1. $\tau - 1 \sim \text{Geom}(1/M)$;
2. $\xi := \eta_\tau \sim \mathcal{P}$;
3. $\tau \perp \eta_\tau$.

Трудоемкость По смыслу, $p = \text{pdf}_{\mathcal{P}}$ сложная в вычислении¹, $q = \text{pdf}_{\mathcal{Q}}$ простая. Чтобы получить одну реализацию нужной случайной величины η_τ , нужно τ раз вычислить r ; в среднем это, поскольку $\tau - 1 \sim \text{Geom}(1/M)$,

$$\mathbb{E}(\tau - 1) = \mathbb{E}(\tau) - 1 = \frac{1 - 1/M}{1/M} = M - 1 \implies \mathbb{E}(\tau) = M.$$

Но M — то, насколько одна плотность подогнана под другую ($M = p/q = 1$ соответствует случаю $p = q$).

Так что важно правильно выбрать мажорирующее распределение, ведь когда отвергается величина $r(\eta^{(t)})$ процессорные такты, потраченные на её вычисление, пропадают.

1.3 Трюки

Следующие трюки позволяют выбирать мажорирующую плотность так, что $M \rightarrow 1$.

Rejection with squeezing Пусть умеем строить не только мажорнату g_u , но и миноранту g_ℓ . Для отбора нужно брать только те, что ниже p ; значит, сначала вычислим миноранту, и если значение ниже нее, то принимать значение.

Adaptive Rejection Sampling (ARS) См. далее.

¹Например, в случае условного распределения — тогда это интеграл $h(x) = \int \ell(x, y) dy$.

2 Адаптивный метод отбора

(Рис. 1) Нужно, чтобы

1. p была непрерывно дифференцируема на связном множестве D .
2. $h(x) = \log p(x)$ была бы выпукла.

Большая часть стандартных плотностей этим требованиям удовлетворяют; интегралы тоже, потому что неравенство Енсена.

2.1 Мажоранта

Мажоранту можно построить кусочно-линейную — по касательным. Пусть выбрано разбиение $x_1 \leq \dots \leq x_k$. Пусть также z_1, \dots, z_{k-1} — точки пересечения касательных:

$$\begin{aligned} z_j &= \frac{h(x_{j+1}) - h(x_j) - x_{j+1}h'(x_{j+1}) + x_jh'(x_j)}{h'(x_j) - h'(x_{j+1})}, \quad j \in 1 : (k-1) \\ z_0 &= -\infty \text{ или } \inf D \\ z_k &= +\infty \text{ или } \sup D. \end{aligned}$$

Тогда можно задать кусочно-линейную мажоранту

$$u(x) = h(x_j) + h'(x_j)(x - x_j), \quad x \in (z_{j-1}, z_j], \quad j \in 1 : k.$$

Потенцировав, получают $\exp u(x)$ — мажоранту исходного распределения \mathcal{Q} , каковая мажоранта задает кусочно-экспоненциальную плотность

$$s(x) = \frac{\exp u(x)}{C}, \quad C = \int_D \exp u(w) dw,$$

где

$$\begin{aligned} \int_D \exp u(w) dw &= \sum_{j=1}^k \int_{z_{j-1}}^{z_j} \exp \{h(x_j) + h'(x_j)(w - x_j)\} dw \\ &= \sum_{j=1}^k \exp \{h(x_j) - h'(x_j)x_j\} \int_{z_{j-1}}^{z_j} \exp \{h'(x_j)w\} dw \\ &= \sum_{j=1}^k \frac{1}{h'(x_j)} \exp \{h(x_j) - h'(x_j)x_j\} (\exp \{h'(x_j)z_j\} - \exp \{h'(x_j)z_{j-1}\}) \\ &= \sum_{j=1}^k \frac{1}{h'(x_j)} (\exp \{h(x_j) + h'(x_j)(z_j - x_j)\} - \exp \{h(x_j) + h'(x_j)(z_{j-1} - x_j)\}) \\ &= \sum_{j=1}^k \frac{1}{h'(x_j)} (\exp u(z_j) - \exp u(z_{j-1})). \end{aligned}$$

2.1.1 Моделирование кусочно-экспоненциальной плотности

Функция распределения кусочно-экспоненциальной плотности \mathcal{Q} есть

$$F_{\mathcal{Q}}(z) = \int_{-\infty}^z s(x) dx = \frac{1}{C} \left(\sum_{j=1}^{i: z_i \geq z} \frac{1}{h'(x_j)} (\exp u(z_j) - \exp u(z_{j-1})) + \exp u(z) - \exp u(z_i) \right).$$

Алгоритм (Моделирование $\eta \sim \mathcal{Q}$).

1. $\alpha \sim U(0, 1)$
2. $z_i \leftarrow \max \{z_j : F_Q(z_j) < \alpha\}$
- 3.

$$\eta \leftarrow z_i + \frac{1}{h'(x_{i+1})} \log \left[1 + \frac{h'(x_{i+1})C(\alpha - F_Q(z_i))}{\exp u(z_i)} \right].$$

2.2 Миноранта

Миноранта — из хорд составленная. Тогда для $x \in [x_j, x_{j+1}]$ миноранта задается как

$$\ell(x) = \frac{(x_{j+1} - x)h(x_j) + (x - x_j)h(x_{j+1})}{x_{j+1} - x_j}, \quad j \in 1 : (k - 1).$$

Для $x < x_1$ или $x > x_k$ $\ell(x) := -\infty$.

Утверждение. Раз h выпукла, то автоматически $e^{\ell(x)} \leq p(x) \leq e^{u(x)}$.

2.3 Алгоритм

Алгоритм. Таким образом,

1. Инициализация:

a) Выберем $T_k = \{x_1, \dots, x_k\}$ — количество начальных точек.

Замечание. Нужно выбрать по крайней мере по разным сторонам от моды — $h'(x_1) > 0$, $h'(x_k) < 0$, чтобы можно было построить мажоранту (минимум две; три с третьей в моде уже гораздо лучше).

b) Посчитаем $h(x_1), \dots, h(x_k)$, $h'(x_1), \dots, h'(x_k)$, z_1, \dots, z_{k-1} . Посчитаем u_j, ℓ_j, s_j .

2. Моделирование (отбор):

a) $\eta \leftarrow Q$, $\alpha \leftarrow U[0, 1]$.

b) если

$$\alpha \leq \exp \{\ell(\eta) - u(\eta)\},$$

то $\xi \leftarrow \eta$; конец.

c) если

$$\alpha \leq \exp \{h(\eta) - u(\eta)\},$$

то $\xi \leftarrow \eta$; конец.

3. Хочется переиспользовать вычисленное значение h (потому что она дорогая) — вычислим производную $h' \leftarrow h'(\eta)$, $T_{k+1} \leftarrow T_k \cup \{\eta\}$ и перепорядочим T_{k+1} . По полученному можно пересчитать $u_{j+1}, \ell_{j+1}, s_{j+1}$.

Замечание. Если дошли до этого шага, значит находимся с большой вероятностью в месте большого зазора мажоранты и h ; значит добавление точки в данном месте очень хорошо этот зазор уменьшает.

Данный алгоритм хорошо аппроксимирует исходную плотностью кусочно-экспоненциальным распределением, так что $M \rightarrow 1$.

Замечание. Если функция оказывается выпуклой после монотонного преобразования, то плотность будет не кусочно-экспоненциальная, а кусочно-какая-то.

Замечание. Если плотность вогнутая, то поменяются хорды и касательные (плюс нужно будет разбираться с асимптотами).

Замечание. Любую хорошую функцию можно разложить на выпуклую и вогнутую части. Тогда можно посчитать как смесь, для чего необходимо почти всегда знание интегралов компонентов смеси.

2.4 ARS с ушами

Пусть не умеем считать производную. Тогда мажоранту можно делать из ушей продолжением хорд (Рис. 2). Пусть $L_{ij}(x)$ — прямая, соединяющая $(x_i, h(x_i))$ и $(x_j, h(x_j))$. Тогда на $x_i \leq x \leq x_{i+1}$, $u_k(x) = \min(L_{i-1,i}(x), L_{i+1,i+2}(x))$. Крайние интервалы нужно, понятно, обрабатывать отдельно.

Adaptive Rejection Metropolis Sampling Пусть есть функция с особенностью — перегибом. Тогда в окрестности перегиба значение мажоранты будет меньше значения функции. Стандартный трюк — отказаться от независимости и в качестве результата выдавать предыдущий результат.