

Support Vector Machines

422 группа

Tue 21 Mar 2017

Содержание

1	Maximum margin classifier	1
2	Support Vector Classifier (soft margin)	2
3	Support Vector Machine (kernels)	3

1 Maximum margin classifier

Пусть задана выборка $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$, $\mathbf{x}_i \in \mathbb{R}^p$, $y_i \in \{-1, 1\}$.

- Гиперплоскость

$$\mathcal{H} = \left\{ \mathbf{x} : f(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x} + \beta_0 = 0 \right\}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}.$$

- Нормаль к \mathcal{H}

$$\nabla f(\mathbf{x}) = \boldsymbol{\beta}.$$

- Расстояние со знаком от \mathbf{x} до проекции $\mathbf{x}_0 \in \mathcal{H}$:

- Пусть $\mathbf{x} \parallel \mathbf{x}'$; тогда $\langle \mathbf{x}, \mathbf{x}' \rangle = \pm \|\mathbf{x}\| \|\mathbf{x}'\|$
- Поскольку $\nabla f(\mathbf{x}_0) \parallel (\mathbf{x} - \mathbf{x}_0)$ и $\boldsymbol{\beta}^\top \mathbf{x}_0 = -\beta_0$,

$$\|(\mathbf{x} - \mathbf{x}_0)\| = \frac{\langle \mathbf{x} - \mathbf{x}_0, \nabla f(\mathbf{x}_0) \rangle}{\|\nabla f(\mathbf{x}_0)\|} = \frac{1}{\|\boldsymbol{\beta}\|} \boldsymbol{\beta}^\top (\mathbf{x} - \mathbf{x}_0) = \frac{1}{\|\boldsymbol{\beta}\|} (\boldsymbol{\beta}^\top \mathbf{x} + \beta_0) = \frac{f(\mathbf{x})}{\|\nabla f(\mathbf{x})\|}.$$

- Если $\|\boldsymbol{\beta}\| = 1$, то расстояние от \mathcal{H} до точки \mathbf{x} есть

$$f(\mathbf{x}).$$

- Оптимизационная задача

$$\max_{\boldsymbol{\beta}, \beta_0} M, \quad \text{subject to } \|\boldsymbol{\beta}\| = 1, \quad f(\mathbf{x}_i) y_i \geq M, \quad i \in 1 : N,$$

что то же

$$\max_{\boldsymbol{\beta}, \beta_0} M, \quad \text{subject to } \frac{f(\mathbf{x}_i)}{\|\boldsymbol{\beta}\|} y_i \geq M \iff f(\mathbf{x}_i) y_i \geq M \|\boldsymbol{\beta}\|, \quad i \in 1 : N,$$

и, т.к. $\forall \boldsymbol{\beta}, \beta_0$ удовлетворяющих неравенств $c \cdot \boldsymbol{\beta}, c \cdot \beta$ тоже удовлетворяет, положим $\|\boldsymbol{\beta}\| = 1/M$, тогда

$$\min_{\boldsymbol{\beta}, \beta_0} \|\boldsymbol{\beta}\|, \quad \text{subject to } f(\mathbf{x}_i) y_i \geq 1, \quad i \in 1 : N.$$

- Лагранжиан

$$L = \frac{1}{2} \|\beta\|^2 - \sum_{i=1}^N \lambda_i (f(\mathbf{x}_i) y_i - 1).$$

- Решение

$$\beta = \sum_{i=1}^N \lambda_i y_i \mathbf{x}_i \quad (1)$$

$$0 = \sum_{i=1}^N \lambda_i y_i. \quad (2)$$

- При подстановке в L , двойственная

$$L_D = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{k=1}^N \lambda_i \lambda_k y_i y_k \mathbf{x}_i^T \mathbf{x}_k, \quad \text{subject to } \lambda_i \geq 0, \sum_{i=1}^N \lambda_i y_i = 0 \quad (3)$$

и еще условия

$$\lambda_i (y_i f(\mathbf{x}_i) - 1) = 0, \quad i \in 1 : N. \quad (4)$$

Максимизируя её получают решение, которое должно удовлетворять ККТ условиям (1)–(4).

- Опорные вектора: из (4) видно, что если $\lambda_i \neq 0$, то $y_i f(\mathbf{x}_i) = 1$ и \mathbf{x}_i лежит на границе; если $y_i f(\mathbf{x}_i) > 1$, то $\lambda_i = 0$. Поэтому в (1) участвуют только вектора на границе — *опорные*.
- Классификатор:

$$G(\mathbf{x}_0) = \text{sign } \hat{f}(\mathbf{x}_0).$$

2 Support Vector Classifier (soft margin)

- Оптимизационная задача

$$\max_{\beta, \beta_0, \epsilon} M, \quad \text{subject to } \|\beta\| = 1, f(\mathbf{x}_i) y_i \geq M(1 - \epsilon_i), \epsilon_i \geq 0 \quad i \in 1 : N, \sum_{i=1}^N \epsilon_i \leq C_0.$$

- C_0 — максимальное количество мисклассифицированных точек:

- ◊ Если $\epsilon_i = 0$, то \mathbf{x}_i лежит снаружи границы
- ◊ Если $\epsilon_i \in (0, 1)$, то внутри с правильной стороны
- ◊ Если $\epsilon_i > 1$, то с неправильной стороны

- Как и прежде, эквивалентной задачей будет

$$\min_{\beta, \beta_0} \|\beta\|, \quad \text{subject to } f(\mathbf{x}_i) y_i \geq 1 - \epsilon_i, \quad i \in 1 : N, \sum_{i=1}^N \epsilon_i \leq C_0$$

что то же,

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^N \epsilon_i, \quad \text{subject to } f(\mathbf{x}_i) y_i \geq 1 - \epsilon_i, \quad i \in 1 : N.$$

- Опорные вектора: теперь лежат как на границе, так и внутри.

3 Support Vector Machine (kernels)

Пусть h_1, \dots, h_M — базисные функции. Можно было бы спроецировать $\mathbf{h}(\mathbf{x}_i) = (h_1(\mathbf{x}_i), \dots, h_M(\mathbf{x}_i))^T$ и в результирующем пространстве построить классификатор. Расширение идеи — ядра. Ядро есть симметричная положительно определенная

$$K(\mathbf{x}, \mathbf{x}') = \langle \mathbf{h}(\mathbf{x}), \mathbf{h}(\mathbf{x}') \rangle.$$

Теорема (Мерцер). Пусть $K(\mathbf{x}, \mathbf{y})$ непрерывное, симметричное, положительно определенное ядро, $\mathbf{x}, \mathbf{y} \in \mathfrak{X}$ (полное, метрическое, сепарабельное). Тогда существует такое гильбертово пространство \mathcal{H} и отображение $\mathbf{h} : \mathfrak{X} \rightarrow \mathcal{H}$ что

$$K(\mathbf{x}, \mathbf{y}) = \langle \mathbf{h}(\mathbf{x}), \mathbf{h}(\mathbf{y}) \rangle_{\mathcal{H}}.$$

Видно, что

$$\begin{aligned} \hat{f}(\mathbf{x}_0) &= \beta_0 + \mathbf{h}(\mathbf{x}_0)^T \hat{\boldsymbol{\beta}} = \beta_0 + \mathbf{h}(\mathbf{x}_0)^T \sum_{i=1}^N \lambda_i y_i \mathbf{h}(\mathbf{x}_i) = \beta_0 + \sum_{i=1}^N \lambda_i y_i \langle \mathbf{h}(\mathbf{x}_0), \mathbf{h}(\mathbf{x}_i) \rangle \\ &= \beta_0 + \sum_{i=1}^N \lambda_i y_i \langle \mathbf{h}(\mathbf{x}_0), \mathbf{h}(\mathbf{x}_i) \rangle = \beta_0 + \sum_{i=1}^N \lambda_i y_i K(\mathbf{x}_0, \mathbf{x}_i), \end{aligned}$$

так что в классификаторе $G(\mathbf{x}_0) = \text{sign } \hat{f}(\mathbf{x}_0)$ участвуют только суммы ядер на опорных векторах (таких, что $0 < \lambda_i < C$).